

# ISTx1002 Usikkerhet og støy i målinger


Usikkerhet og feil i variabler i regresjon

Stefanie Muff, Institutt for matematiske fag, NTNU Trondheim

Oktober 31 2023

## Plan for i dag

- Lineær regresjon
- Klassisk målefeil i en forklaringsvariabel
- To strategier for å handtere målefeil:
  - Med en analytisk formel  $\rightarrow$  Attenueringsfaktor
  - Med en heuristisk idé  $\rightarrow$  SIMEX



# Pensum og læringsressurser

Husk lenken til den eksterne modulsiden:

<https://wiki.math.ntnu.no/istx1002/2023h/start>

Pensum del 3:

- Denne forelesningen
- **Disse slides** med alle notater og beregninger som er vist fram
- Shiny app: [https://stefaniemuff.shinyapps.io/MEC\\_ChooseL/](https://stefaniemuff.shinyapps.io/MEC_ChooseL/)

# Oversikt

- Usikkerhet og målefeil i en variabel ( $x$ ) i en enkel lineær regresjon.
- Effekt av usikkerhet og målefeil i regresjon.
- Når bør man være bekymret?
- Enkle metoder for å korrigere for usikkerhet og feil i en regresjonsvariabel.
- Vi skal finne ut på hvordan målefeil i våre reaksjonstider påvirker en regresjon hvor vi vil forstå sammenheng mellom reaksjonstid og timer søvn:

[https://docs.google.com/spreadsheets/d/1jswtNl8zmIdWwjuuRKS\\_nKzAN-M5DLFI\\_SrnCIXl17w10/edit#gid=0](https://docs.google.com/spreadsheets/d/1jswtNl8zmIdWwjuuRKS_nKzAN-M5DLFI_SrnCIXl17w10/edit#gid=0)

## Kilder til usikkerheit og målefeil i regresjonsvariabler.

- **Upresise målinger** i feltarbeid eller labor (lengde, vekt, blodtrykk...)
- Feil grunnet **ufullstendige eller skjeve observasjoner** (for eksempel selvrapporterte kostvaner, helsehistorie).
- Skjeve observasjoner grunnet **preferansebasert utvalg** eller gjentatte observasjoner.
- Avrundingsfeil, sifferpreferanse.
- **Feilklassifisering** (for eksempel feil i eksponerings- eller sykdomsklassifisering).

Merk: “Feil” og “usikkerhet” er ofte brukt synonymt.


## Lineær regresjon - hva var det igjen for noe?

### Motiverende eksempel


- Kroppsfett er en viktig indikator for overvekt, men vanskelig å måle.

**Spørsmål:** Hvilke faktorer tillater præsis estimering av kroppsfettet?

Vi undersøker 243 mannlige deltakere. Kroppsfett (%), BMI og andre forklaringsvariabler ble målet. Kryssplott:



Vi begynner med *enkel lineær regresjon* (regresjon med bare en forklaringsvariabel):



# Enkel lineær regresjon

- En kontinuerlig responsvariabel  $Y$
- Bare *en forklaringsvariabel*  $x$
- Relasjon mellom  $Y$  og  $x$  er antatt å være *lineær*.


Hvis den lineære relasjonen mellom  $Y$  og  $x$  er perfekt, så gjelder

$$y_i = \beta_0 + \beta_1 x_i$$

for alle  $i$ . Men..




Hvilken linje er best?



## Enkel lineær regresjon

a) Kan vi tilpasse den “rette” eller “beste” linjen til dataene?



- $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ .
- $\hat{e}_i = \hat{y}_i - y$
- $\hat{\beta}_0$  og  $\hat{\beta}_1$  velges slik at

$$SSE = \sum_i \hat{e}_i^2$$


minimeres.

# Lineær regresjon – fundamentale antakelser

$$Y_i = \underbrace{\beta_0 + \beta_1 x_i}_{\hat{y}_i} + \varepsilon_i$$

med

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2) .$$



Gjør vi andre antagelser for en lineær regresjonsmodell?

Ja! Men hvilke?


[www.menti.com](http://www.menti.com)

## “Klassisk” målefeil

Kanskje det mest vanlige tilfelle av feil og usikkerhet er så-kalt *klassisk målefeil*.

Vi vil måle størrelsen  $X$ , men vi kan bare måle  $W$  med feil  $U$ :

$$\begin{aligned} W &= X + U \\ U &\sim N(0, \sigma_u^2) . \end{aligned}$$



**Eksempel:** Måling av vår reaksjonstid, upresise målinger av en konsentrasjon, en vekt etc.

Men hva skjer hvis variabel  $x$  har målefeil/usikkerhet, og inngår som forklaringsvariabel i en regressjon?


Du kan se selv:

[https://stefaniemuff.shinyapps.io/MEC\\_ChooseL/](https://stefaniemuff.shinyapps.io/MEC_ChooseL/)

## Illustrasjon

Vi genererer data som samsvarer med modellen nedenfor, og så vil vi estimere  $\beta_0$  og  $\beta_x$ . Vi vet at  $X \sim N(0, \sigma_x^2)$  med  $\sigma_x^2 = 1$ , og


$$Y = \underbrace{1}_{\beta_0} + \underbrace{2}_{\beta_x} \cdot X + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2) \quad \text{med} \quad \sigma^2 = 1.$$



## Illustrasjon, del II

Det dumme er at vi ikke kjenner  $X$ , men bare en upresis versjon  $W$  som vi kan bruke som forklaringsvariabel:

$$W = X + U, \quad U \sim N(0, \sigma_u^2) \quad \text{med } \sigma_u^2 = 0.8 .$$






## Den “tredoble utfordringen med målefeil”

(Carroll et al., 2006)

1. **Skjevhet (bias)**: Inkludering av feilaktige variabler i etterfølgende analyser kan føre til skjeve estimater av parameter.
2. ME fører til en **tap av styrke (power)** for å oppdage signaler.
3. ME **skjuler viktige egenskaper** ved dataene, noe som gjør det vanskelig å inspisere grafiske modeller.



## Hvordan kan vi handtere målefeil i en regressjonsvariabel?

- Generelt sett hjelper det når man har en idé hvordan feil og usikkerhet oppstår.
- Konkret trenger vi en **feilmodell** og kunnskap om **parametrene** i feilmodellen.

**Eksempel:** For klassisk målefeil  $W = X + U$  med  $U \sim N(0, \sigma_u^2)$  trenger vi kunnskap om variansen  $\sigma_u^2$ .

### Mulige Strategier:

- 1) Ta gjentatte målinger (som for reaksjonstiden), så kan du estimere variansen (i.e., usikkerheten).
- 2) Bruk kunnskap om modellen og usikkerheten i  $X$  for å korrigere feilen i regresjonsparametrene (særlig i  $\beta_x$ ).

## En formel for å handtere et enkelt tilfelle

Vi fortsetter med klassisk målefeil i lineær regresjon  $y = \beta_0 + \beta_x x + \varepsilon_i$  hvor vi dessverre bare måler en feilaktig versjon  $w = x + u$ .

Siden vi ikke kjenner  $x$ , har vi i første omgang ikke noe annet valg enn å bruke  $w$  og tilpasse en modell gitt som

$$y = \beta_0^* + \beta_x^* w + \varepsilon_i .$$

Er det en god idé?

Vi har jo sett at parameteren  $\beta_x^* < \beta_x$ , og det viser seg at den forventete verdien reduseres med en faktor  $\lambda < 1$

$$E[\beta_x^*] = \underbrace{\frac{\sigma_x^2}{\sigma_x^2 + \sigma_u^2}}_{\lambda} \beta_x , \quad (1)$$

hvor  $\lambda$  heter **attenueringsfaktor**.

### Oppgave:

- Se igjen på eksempelet vi brukte for illustrasjon. Hvor mye reduksjon forventer vi i estimaten til stigningstallet  $\beta_x$ ?
- I praksis har vi jo *ikke* tilgang til de ekte verdiene  $x$ , men kjenner bare de med usikkerhet  $w$ . Hvordan kan du bruke kunnskapet om formel (1) for å finne en korrigert versjon for estimaten av  $\beta_x$ ?

**Utgning:**



Dessverre finnes det ikke mange tilfeller hvor vi har noe som formel (1).

## En heuristisk idé: Simulation Extrapolation (SIMEX)

Foreslått av Cook og Stefanski (1994).

SIMEX består av to faser:

- **Fase 1: Simulasjon.** Usikkerheten i dataene ( $x$  variable) blir gradvis økt for å forstå hvordan størrelsen av interesse (vanligvis en regresjonsparameter/stigningstall  $\beta_x$ ) påvirkes av feilen/usikkerheten.
- **Fase 2: Ekstrapolasjon.** Den observerte trenden ekstrapoleres deretter *tilbake* til en hypotetisk feilfri verdi.




## Illustrasjon av SIMEX ideen


Størrelsen av interesse:  $\beta_x$  (stigningstall i en regresjon).

**Problem:** Forklaringsvariablen  $x$  er målt med usikkerhet:

$$w = x + u, \quad u \sim N(0, \sigma_u^2).$$



## Exempel 1: Våre reaksjonstider



Modell:

$$y_i = \beta_0 + \beta_x x_i + \varepsilon_i, \quad \varepsilon_i = N(0, \sigma^2),$$

med  $x_i$ =timer søvn, og  $x_i$ =reaksjonstid til person  $i$ , målt i 3. omgang.

**Problem:** Vi vet jo at reaksjonstiden er ganske unøyaktig og har mye målefeil i seg. Vi kan estimere feilvariansen (det har jeg gjort for dere ved bruk av deres data), og resultatet blir

$$\sigma_u^2 = 565 .$$

For å bruke SIMEX proseduren, antar vi jo

$$w_i = x_i + u_i , \quad u_i \sim N(0, \sigma_u^2) .$$

Det er en ganske plausibel antakelse, og så bruker vi SIMEX proseduren!

Vi sammenligner

- en regresjon hvor vi bruker reaksjonstiden ved 3. måling som forklaringsvariable, med
- en korrigert versjon som vi får etter vi anvender SIMEX proseduren.



### Naiv resultat med med feilaktig BMI:

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	9.392168756	0.669439617	14.029897	3.852253e-19
## Reaction_time_3	-0.006616798	0.002374351	-2.786782	7.458553e-03


### Estimater etter SIMEX-korrektoren ble anvendt:

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	9.543600821	0.559054066	17.070980	9.805241e-23
## Reaction_time_3	-0.007199182	0.001912446	-3.764384	4.328353e-04

Se på grafiske resultater med en kvadratisk ekstrapolasjonsfunksjon:



Uten (rødt) og med korrektur (svart):



**Interpretasjon av resultatet?**

## Eksempel 2: Sammenheng av BMI og kropps fett

Vi ser igjen på en regresjonsmodell med kropps fett som respons ( $y$ ) og BMI som forklaringsvariabel  $x$ :

$$y_i = \beta_0 + \beta_x x_i + \varepsilon_i, \quad \varepsilon_i = N(0, \sigma^2)$$

med

$\mathbf{y} = (y_1, \dots, y_{100})^\top$ : variabel med % kropps fet målt ved 100 personer.

**Problemet:** BMI-en ble selvrapportert og har derfor målefeil! Ikke  $x_i$  blir observert, men heller

$$w_i = x_i + u_i, \quad u_i \sim N(0, 4) .$$

→ Bruk SIMEX proseduren!

Vi sammenligner

- en regresjon hvor vi bruker den feilaktige BMI-en som forklaringsvariabel, med
- en korrigert versjon som vi får etter vi anvender SIMEX proseduren.

### Naiv resultat med med feilaktig BMI:



##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	-6.240988	2.12868299	-2.931854	4.194014e-03
## BMI	1.214017	0.08860899	13.700829	1.673886e-24

### Estimater etter SIMEX-korrektoren ble anvendt:


##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	-12.851018	3.1273875	-4.109186	8.247864e-05
## BMI	1.492441	0.1275759	11.698449	2.632916e-20



Se på grafiske resultater med en kvadratisk ekstrapolasjonsfunksjon:



Uten (rødt) og med korrektur (svart):



# Multipel lineær regresjon

Nesten det samme som enkel lineær regresjon, vi bare summerer flere forklaringsvariabler:

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2) .$$

For eksempel:

$$\text{bodyfat}_i = \beta_0 + \beta_1 \text{bmi}_i + \beta_2 \text{age}_i + \varepsilon_i .$$

Hva skjer hvis en variabel i en *multippel regresjon* har usikkerhet?

**Exempel:** Vi ser igjen på en regresjonsmodell med kropps fett som respons ( $y$ ) og BMI ( $x$ ) som forklaringsvariabel, men nå har vi i tillegg også kjønn ( $z$ ) som forklaringsvariabel:

$$y_i = \beta_0 + \beta_x x_i + \beta_z z_i + \epsilon_i, \quad \epsilon_i = N(0, \sigma^2)$$

med  $\mathbf{y}$  og  $\mathbf{x}$  som før, med

$$w_i = x_i + u_i, \quad u_i \sim N(0, 4),$$

og den binære variabeln  $\mathbf{z} = (z_1, \dots, z_{100})^\top$  som indikerer om person  $i$  er en mann ( $z_i = 1$ ) eller en kvinne ( $z_i = 0$ ).

Vi sammenligner igjen

- en regresjon hvor vi bruker den feilaktige BMI-en som forklaringsvariabel, med
- en korrigert versjon fra SIMEX.


### Naiv resultat med feilaktig BMI::

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	-8.003714	2.07060335	-3.865402	2.005407e-04
## BMI	1.271558	0.08821382	14.414504	7.478782e-26
## kjønn	-1.951735	0.73625960	-2.650879	9.376840e-03

### Estimater etter SIMEX-korrektoren ble anvendt:

##	Estimate	Std. Error	t value	Pr(> t )
## (Intercept)	-14.689940	2.6954519	-5.449899	3.825138e-07
## BMI	1.564059	0.1159075	13.494022	5.467540e-24
## kjønn	-2.462127	0.7906688	-3.113980	2.426632e-03

Grafiske resultater med kvadratisk ekstrapolasjonsfunksjon:



**Merk:** Variabelen `kjønn` har ikke blitt feilmålt, likevel er stigningstallet påvirket av feilen i BMI!

**Grunn:** `kjønn` og BMI er korrelert.